



Point d'étape — Semaine 1 (10 septembre 2026)

🇫🇷 Youssef El Alaoui —
Stage M2 LIRMM
Point d'étape du 10
septembre 2026

🇬🇧 Youssef El Alaoui — MSc
internship, LIRMM
Progress meeting, 10
September 2026

1. Cette semaine ·

- Lecture de l'article de référence (Salehi et al., 2024)
- Exploration du dataset Zenodo
- Réplication du pipeline sur 20 découpages

This week

- Read the reference paper (Salehi et al., 2024)
- Explored the Zenodo dataset
- Replicated the pipeline over 20 splits

2. Le dataset ·

**154 patients × 51 colonnes →
24 features exploitables**

Cible	Distribution
effectiveness	98 / 56
sustained	85 / 69
remission	77 / 77

The dataset

**154 patients × 51 columns →
24 usable features**

Target	Distribution oui/non
effectiveness	98 / 56
sustained	85 / 69
remission	77 / 77

Cinq problèmes de qualité · quality issues

1. **Dataset déjà imputé** — 1 seule valeur manquante, contre 16 % annoncés. La fuite du MICE est incorporée dans les valeurs.
2. **22 colonnes constantes sur 51** — dont les 17 comorbidités à zéro et **bDMARD** à 1, donc **la molécule administrée est absente**. (Ça veut dire qu'on ne sait pas **quel médicament** chaque patient a reçu parmi les 12.)
3. **62 % des CDAI/SDAI ne se recalculent pas** depuis leurs composantes. 15 patients ont un SDAI < CDAI, ce qui impliquerait une CRP négative. Ce n'est pas l'imputation.
4. **sustained** : **85/69 dans le fichier, 66/88 dans l'article**. Le Tableau A3 correspond au 85/69.
5. **Trois valeurs aberrantes** — BMI = 192, un patient de 15 ans, et **tptID 5399** étiqueté répondeur soutenu tout en étant non-répondeur.

Five data

1. **Dataset already imputed** — only 1 missing value, versus 16% reported. The MICE leakage is baked into the values.
2. **22 constant columns out of 51** — including all 17 comorbidities at zero and **bDMARD** at 1, so **the administered drug is missing**.
3. **62% of CDAI/SDAI do not recompute** from their components. 15 patients have SDAI < CDAI, which would imply a negative CRP. This is not the imputation.
4. **sustained** : **85/69 in the file, 66/88 in the paper**. Table A3 matches the 85/69 split.
5. **Three outliers** — BMI = 192, a 15-year-old patient, and **tptID 5399** labelled sustained responder while being a non-responder.

3. Le résultat principal • result

Le label est le DAS28-ESR à **6 mois**. La variable la plus prédictive est le DAS28-ESR **au jour 0**. On prédit une mesure à partir d'elle-même.

87 % des « répondeurs » étaient déjà sous le seuil avant traitement.

Modèle	Accuracy
Règle « DAS28 < 3,2 », sans apprentissage	0,876
LogReg, DAS28 seul	0,844
<i>XGBoost de l'article</i>	<i>0,851</i>

Le test décisif — en ne gardant que les patients en activité modérée à forte (DAS28 $\geq 3,2$, $n = 63$) :

Cohorte	AUC du DAS28 seul
Complète (154)	0,915
Restreinte (63)	0,493

0,493 = le hasard. Mais un Random Forest y atteint **0,657**, soit +0,16 : il reste du signal dans les autres variables.

Main

The label is DAS28-ESR **at 6 months**. The most predictive variable is DAS28-ESR **at day 0**. We predict a measurement from itself.

87% of "responders" were already below the threshold before treatment.

Model	Accuracy
Rule "DAS28 < 3.2", no training	0.876
LogReg, DAS28 only	0.844
<i>XGBoost from the paper</i>	<i>0.851</i>

The decisive test — keeping only patients with moderate-to-high activity (DAS28 ≥ 3.2 , $n = 63$):

Cohort	AUC of DAS28 alone
Full (154)	0.915
Restricted (63)	0.493

0.493 = chance. But a Random Forest reaches **0.657** there, i.e. +0.16: signal remains in the other variables.

4. Réplication •

Replication

Le chiffre phare se reproduit :
XGBoost à **0,913** d'AUC contre
0,910 publiée.

Mais sur 20 découpages, **trois vainqueurs différents** :
Random Forest 10, SVM 6,
XGBoost 4. Aucune différence
significative entre les trois ($p = 0,35$ à $0,93$).

Conséquence : un gain de
0,01 d'AUC du Modèle B sur
le Modèle A ne signifierait
rien. Il faut au moins 0,03–
0,05, sur plusieurs seeds,
avec un test apparié.

The headline figure replicates:
XGBoost at **0.913** AUC versus
0.910 published.

But across 20 splits, **three different winners**: Random
Forest 10, SVM 6, XGBoost 4.
No significant difference
between the three ($p = 0.35$ to
 0.93).

Consequence: a 0.01 AUC
gain of Model B over Model
A would mean nothing. At
least 0.03–0.05 is needed,
across several seeds, with a
paired test.

5. Pour les Modèles A et B • For Models A and B

Nettoyage identique pour A et B, sinon on compare deux jeux de données et non deux approches.

Où l'ontologie peut démontrer un apport, chiffres à l'appui :

- axiomes arithmétiques
($SDAI = CDAI + CRP$) → 95 violations
- contraintes logiques
($sustained \Rightarrow effectiveness$)
→ 1 violation
- critères d'éligibilité (âge ≥ 18) → le patient de 15 ans

Identical cleaning for A and B, otherwise we compare two datasets rather than two approaches.

Where the ontology can demonstrate value, with figures:

- arithmetic axioms ($SDAI = CDAI + CRP$) → 95 violations
- logical constraints
($sustained \Rightarrow effectiveness$)
→ 1 violation
- eligibility criteria (age ≥ 18)
→ the 15-year-old patient

- contrôle qualité (une variable constante ne peut avoir de valeur SHAP) → 17 comorbidités, dont une publiée en Figure 4B

Protocole proposé : comparer trois versions du dataset — CDAI/SDAI tels quels, supprimés, recalculés.

CDAI — Clinical Disease Activity Index

SDAI — Simplified Disease Activity Index

Version	CDAI / SDAI
V1	tels quels
V2	supprimés
V3	recalculés

Si V3 dépasse V1, l'apport de l'ontologie est chiffré. Si les trois se valent, le résultat reste exploitable : 95 patients portaient des valeurs cliniquement fausses, détectables uniquement par une approche sémantique.

- quality control (a constant variable cannot have a SHAP value) → 17 comorbidities, one published in Figure 4B

Proposed protocol: compare three dataset versions — CDAI/SDAI as-is, dropped, recomputed.

CDAI — Clinical Disease Activity Index

SDAI — Simplified Disease Activity Index

Version	CDAI / SDAI
V1	as-is
V2	dropped
V3	recomputed

If V3 beats V1, the ontology's contribution is quantified. If all three are equivalent, the result is still usable: 95 patients carried clinically wrong values, detectable only through a semantic approach.

6. Questions

1. Sur quelle formulation de la

tâche travailler ? La cible actuelle est déterminée par une seule variable. $DAS28 \leq 3,2$.

2. Quelle version de `sustained` a servi à l'entraînement — 85/69 ou 66/88 ?

3. Peut-on obtenir les données brutes avant imputation ?

4. Les CDAI/SDAI ont-ils été joints depuis une autre visite ?

5. À quoi correspond `remission` (77/77) ?

6. `bDMARD_intake_duration_days` : baseline ou suivi ?

Lecture A — baseline. Le patient prenait déjà cette biothérapie avant d'entrer dans l'étude, et la colonne dit depuis combien de temps. C'est une information légitime, disponible au jour 0, utilisable comme feature.

Lecture B — suivi. C'est la durée totale pendant laquelle il a pris le traitement, mesurée à la fin. Là, c'est une fuite majeure.

7. Le nom de la molécule est-il récupérable ?

8. BMI = 192 et patient de 15 ans : à exclure ?

1. Which formulation of the

task should we work on? The current target is determined by a single variable. $DAS28 \leq 3.2$.

2. Which version of `sustained` was used for training — 85/69 or 66/88?

3. Can we get the raw pre-imputation data?

4. Were CDAI/SDAI joined from a different visit?

5. What does `remission` (77/77) correspond to?

6. `bDMARD_intake_duration_days` : baseline or follow-up?

7. Is the drug name recoverable?

8. BMI = 192 and the 15-year-old: exclude?

MIMIC DATASET